

利用TD3训练神经网络使四旋翼无人机飞越FPV门

December 19, 2024

Virginia Polytechnic Institute and State University National Security Institute

Patrick Thomas, Kevin Schroeder, Jonathan Black

AI 摘要

弗吉尼亚理工大学的研究人员应用TD3算法开发了一种神经网络速度控制器，使四旋翼无人机能够在模拟环境中自主通过第一人称视角（FPV）竞速门。在调整模拟飞行器动力学后，经过训练的策略成功迁移到物理无人机上，在混合现实环境中展示了通过虚拟门的受控飞行。

目录

1. 基于强化学习的无人机自主穿越FPV门导航
2. TD3算法的核心原理
3. 模拟环境
4. 奖励塑形与训练目标
5. 仿真到现实迁移与硬件部署
6. 性能评估与结果
7. 意义与未来方向

1. 基于强化学习的无人机自主穿越FPV门导航

无人机自主导航的挑战通常集中于飞行器以高精度和高速度穿越复杂障碍物的能力。特别是，穿越第一人称视角（FPV）竞速门需要一个控制器，该控制器能够在高速机动时应对现实世界中的不确定性，例如传感器噪声和风。传统的控制策略，如比例-微分（PD）控制器，一直是四旋翼飞行器的标准。然而，这些方法通常需要针对每个环境进行详尽的手动调优，并且对无人机和门的精确位置高度敏感。

最近的研究已转向深度强化学习（DRL）以解决这些局限性。与传统控制器不同，基于DRL的系统可以通过在模拟环境中的经验学习导航策略，从而有可能发展出更鲁棒的行为。这项工作探索了双延迟深度确定性策略梯度（TD3）算法的应用，以训练神经网络使四旋翼飞行器穿越FPV门，并强调从模拟到实际飞行的过渡。



图1：用于无人机竞赛的FPV竞速门，其上带有用于姿态估计的AprilTag。

2. TD3算法的核心原理

双延迟深度确定性策略梯度（TD3）算法是一种最先进的连续控制强化学习方法。它是一种离策略（off-policy）、演员-评论家（actor-critic）算法，这意味着它从先前收集的数据中学习，并维护两种独立类型的网络：一个“演员”网络，负责决定采取何种动作；一个“评论家”网络，负责评估该动作的质量。

TD3旨在改进深度确定性策略梯度（DDPG）算法，后者经常遭受稳定性问题和Q函数（在给定状态下采取某个动作的预期总奖励）过高估计的困扰。为了解决这些问题，TD3引入了三个关键机制：

- 1. 截断双Q学习（Clipped Double-Q Learning）：** 该算法维护两个独立的评论家网络。在计算训练目标值时，它取两个估计值中的最小值。这可以防止评论家对某些动作的价值过于乐观，从而导致更稳定的策略更新。
- 2. 延迟策略更新（Delayed Policy Updates）：** TD3不像在每个训练步骤都更新演员网络，而是比评论家网络更新频率更低（例如，每两个步骤更新一次）。这确保了评论家的价值估计在用于指导演员策略的改变之前具有足够的准确性。
- 3. 目标策略平滑（Target Policy Smoothing）：** 为了使策略更鲁棒，TD3在训练期间向目标演员网络选择的动作中添加少量随机噪声。这鼓励算法找到一个在一系列相似动作中都能很好工作的策略，而不是利用Q函数中的尖锐峰值。

在训练期间，演员网络接收一个8元素的状态向量，表示四旋翼飞行器相对于门的位置（ X, Y, Z ）、偏航角、速度（ V_x, V_y, V_z ）和偏航角速率。它输出四个速度和偏航角速率指令来引导无人机。

3. 模拟环境

由于存在坠机风险以及强化学习所需的大量数据，在现实世界中训练无人机是不切实际的。因此，作者开发了一个与Gymnasium库集成的自定义模拟环境。该环境将四旋翼飞行器建模为一个质点，从而将四个独立电机的复杂物理特性简化为一组更易于管理的基于速度的控制指令。

四旋翼飞行器对指令的物理响应采用一阶动力学建模。在模拟的确定性版本中，水平速度（ V_x, V_y ）的响应速率设置为 $\tau = 0.4 \text{ s}$ ，而垂直速度（ V_z ）和偏航速率（ V_{yaw} ）的响应更快，为 $\tau = 0.1 \text{ s}$ 。

为了提高所学策略的鲁棒性，研究人员在环境中引入了随机性。这包括：

- 在每个训练回合中，从一个分布中随机采样响应速率 τ 。
- 添加从截断正态分布中采样的速度噪声。
- 通过周期性地改变门框的感知位置来引入门框位置不确定性，模拟现实世界计算机视觉系统中存在的噪声。




图2：模拟训练环境中四旋翼飞行器和门框的人眼视角渲染图。

模拟频率设置为 $f_s = 50 \text{ Hz}$ ，与真实飞行控制器中常用的控制循环频率相匹配。这种对齐对于确保模拟中学习到时序能够正确地转移到物理硬件至关重要。

4. 奖励塑形与训练目标

在强化学习中，“奖励函数”定义了智能体的目标。对于这项任务，奖励被设计为鼓励无人机尽快穿过门框中心而不发生碰撞。

采用了密集奖励函数，在每个时间步而非仅在飞行结束时提供反馈。无人机因减小其与门框中心的距离以及保持其朝向门框的方向（偏航）而获得正奖励。相反，它因以下情况而获得显著的负奖励：

- 与门框结构相撞。
- 飞出模拟空间定义的边界。
- 撞击地面。

如果无人机成功穿过门框中心的一个小型“成功区域”，它将获得一个较大的最终奖励。这些项的组合迫使神经网络在速度和精度之间找到平衡。训练需要付出巨大的努力；模型需要大约50万个模

拟步骤才能开始稳定地穿过门框，并需要多达250万个步骤才能掌握现实世界相机使用所需的偏航对齐。



图3：15,000个训练回合中得分的移动平均值，显示了策略学习过程的进展。

5. 仿真到现实迁移与硬件部署

项目中 G 最困难的阶段是“仿真到现实”迁移——将在一个简化的虚拟世界中训练出的策略应用于物理无人机。硬件设置包括一个配备Pixhawk 4飞行控制器和充当机外计算机的树莓派4B的四旋翼飞行器。神经网络从TensorFlow导出，并使用TensorFlow Lite针对树莓派进行了优化。

树莓派与飞行控制器之间的通信通过ROS（机器人操作系统）进行处理。为了跟踪无人机在实验室中的位置，使用了OptiTrack运动捕捉系统。该系统提供了“地面实况”位置数据，使无人机能够知道其相对于实验室空间中虚拟门框的精确位置。

一项重要发现是策略对飞行器动力学模型的敏感性。在首次真实世界飞行测试中，无人机在垂直(Z)轴上表现出不稳定、振荡的行为。研究人员发现，初始仿真低估了真实无人机垂直推力的响应速度。通过测量硬件上的实际响应时间并更新仿真参数，他们能够重新训练一个性能更可靠的新网络。



图4：用于实验室真实世界飞行测试的物理四旋翼飞行器。

6. 性能评估与结果

对训练过的TD3策略的评估侧重于其在保持稳定性的同时，指挥无人机飞向门框中心的能力。最终飞行测试的结果表明，重新训练的神经网络成功地将无人机导航至门框坐标。

分析速度数据时，研究人员发现，在模型改进后，神经网络发出的指令速度与无人机实际达到的速度吻合良好。然而，与传统方法相比，基于RL的控制器仍然表现出一定程度的振荡。

关键性能洞察包括：

- **样本效率低下：** TD3需要数百万步才能达到高性能，这突出了强化学习(RL)相对于分析控制方法的常见缺点。
- **超参数敏感性：** 学习过程高度依赖于特定参数的调整，例如学习率（执行器为 $\alpha = 1 \times 10^{-5}$ ，评论家为 $\beta = 2 \times 10^{-5}$ ）。
- **对不确定性的鲁棒性：** 尽管存在振荡，智能体仍证明它能够处理模拟的门框不确定性，并将该逻辑转化为物理环境。

7. 意义与未来方向

这项工作表明，像TD3这样的离策略强化学习算法可以成功地学习一个控制策略，用于四旋翼飞行

器导航FPV门框。它强调了在树莓派等低功耗、现成的硬件上运行这些复杂神经网络的可行性。

这项研究的主要贡献在于详细记录了“仿真到现实”的差距。通过展示模型响应时间（ τ 参数）的差异如何直接导致现实世界的不稳定性，这项研究为其他尝试类似迁移的研究人员提供了路线图。

未来这方面的工作可能涉及使用更复杂的神经网络架构，例如长短期记忆（LSTM）网络，它们可以记忆过去的状态，以更好地处理加速度和动量。此外，研究人员建议，基于模型的强化学习可以减少目前所需的数百万训练步骤，从而使自主无人机策略的开发更快、更高效。尽管基于RL的控制器尚未超越完美调优的PD控制器的平滑性，但这项研究证实了其在处理自主无人机竞赛中典型的高风险、随机环境方面的潜力。

解决 Actor-Critic 方法中的函数逼近误差

这个引用至关重要，因为它介绍了双延迟深度确定性策略梯度 (TD3) 算法。主论文明确地是这种特定的强化学习方法在控制四旋翼飞行器方面的实现和应用，因此使其成为最基础的参考文献。

Fujimoto, S., van Hoof, H., and Meger, D., “Addressing Function Approximation Error in Actor-Critic Methods,” CoRR, Vol. abs/1802.09477, 2018. URL <http://arxiv.org/abs/1802.09477>.

基于深度强化学习的连续控制

本文介绍了深度确定性策略梯度 (DDPG) 算法，主论文指出该算法是 TD3 的直接前身。这是一篇重要的参考文献，因为作者指出 TD3 改进了 DDPG 的缺点，并且他们直接使用了 DDPG 实现中的噪声过程用于他们自己的模型。

Lillicrap, T. P., Hunt, J. J., Pritzel, A., Heess, N. M. O., Erez, T., Tassa, Y., Silver, D., and Wierstra, D., “Continuous control with deep reinforcement learning,” CoRR, Vol. abs/1509.02971, 2015.

开放AI训练场

这项引用是本文方法论的基础。作者指出，他们用于训练四旋翼飞行器策略的整个模拟环境是在 Gymnasium（OpenAI Gym的维护版本）中开发的，这使得该软件框架对实验设置至关重要。

Brockman, G., Cheung, V., Pettersson, L., Schneider, J., Schulman, J., Tang, J., and Zaremba, W., “Openai gym,” arXiv preprint arXiv:1606.01540, 2016.